PANDUAN PROYEK AKHIR
MATA KULIAH BIG DATA



PROGRAM STUDI S1 INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS NEGERI SURABAYA

1. Deskripsi Proyek

Pada proyek akhir ini, setiap kelompok mengembangkan solusi analisis data menggunakan teknologi Big Data. Mahasiswa dapat memilih dataset dari Kaggle atau menggunakan API yang dapat digunakan secara gratis. Proyek berfokus pada pengelolaan dan pengolahan data, bukan hanya penerapan algoritma machine learning.

Setiap kelompok wajib mengintegrasikan pengumpulan data, penyimpanan menggunakan Hadoop Distributed File System (HDFS), pengolahan menggunakan Apache Spark, serta penerapan minimal satu algoritma machine learning melalui Spark MLlib. Hasil proyek disusun sebagai implementasi program, analisis eksperimen, dan draf artikel ilmiah.

2. Capaian Pembelajaran Mata Kuliah

1. Memanfaatkan Hadoop, Spark dan alat Big Data lainnya
2. Mampu menganalisis, menginterpretasi dan memvisualisasikan hasil pemrosesan data besar untuk menghasilkan wawasan yang dapat ditindaklanjuti dan mengkomunikasikannya secara efektif.
3. Bekerja dengan basis data NoSQL untuk penyimpanan data.
4. Mengimplementasikan alur pemrosesan data

3. Arsitektur Sistem yang Diharapkan

Sumber Data → HDFS → Apache Spark → Spark MLlib → Evaluasi Hasil → Draf Artikel

Tahapan	Aktivitas
1. Pengumpulan data	Mengunduh dataset, menggunakan API, atau melakukan web crawling sesuai ketentuan sumber data.
2. Penyimpanan data	Menyimpan dataset mentah ke HDFS.
3. Pengolahan data	Membaca data dari HDFS menggunakan Spark, membersihkan data atau data preprocessing.
4. Analisis data	Melakukan minimal tiga analisis menggunakan Spark SQL atau DataFrame API.
5. Machine learning	Data yang telah dibersihkan, selanjutnya diterapkan satu algoritma dari Spark MLlib.
6. Evaluasi	Mengukur performa model dan/atau waktu pemrosesan berdasarkan skenario eksperimen.
7. Penyajian hasil	Membuat kesimpulan, demonstrasi program, dan draf artikel ilmiah.

Opsional: Pada penyajian hasil, NoSQL seperti MongoDB dapat digunakan untuk menyimpan dokumen JSON, ringkasan analisis, atau hasil prediksi yang akan dibaca kembali oleh aplikasi. NoSQL merupakan komponen tambahan, bukan pengganti HDFS dan Spark.

4. Pembagian Topik Kelompok

Setiap kelompok memilih satu topik berikut. Topik lain dapat diusulkan dengan persetujuan dosen, selama memenuhi persyaratan teknologi dan eksperimen.

Kelompok	Topik	Permasalahan yang Dikaji	Algoritma yang Disarankan
1	Analisis penjualan e-commerce	Mengelompokkan pelanggan berdasarkan pola pembelian atau mengklasifikasikan kategori transaksi.	Decision Tree
2	Performa akademik mahasiswa	Mengklasifikasikan kategori performa akademik berdasarkan atribut yang relevan.	Random Forest

3	Kemacetan lalu lintas	Mengklasifikasikan tingkat kemacetan berdasarkan atribut lalu lintas yang tersedia.	Logistic Regression
4	Klasifikasi berita Indonesia	Mengklasifikasikan berita ke kategori politik, olahraga, teknologi, ekonomi, dan sebagainya.	Naive Bayes
5	Segmentasi pelanggan	Mengelompokkan pelanggan berdasarkan frekuensi, nilai, dan pola transaksi.	K-Means
6	Prediksi harga rumah	Memperkirakan harga rumah berdasarkan karakteristik properti.	Linear Regression
7	Analisis keranjang belanja	Menemukan kombinasi produk yang sering dibeli bersama.	FP-Growth
8	Kualitas udara	Mengklasifikasikan kualitas udara berdasarkan atribut dan ambang batas yang jelas.	Linear SVC
9	Sistem rekomendasi film	Memberikan rekomendasi berdasarkan interaksi atau rating pengguna.	ALS
10	Riwayat pembelian atau subscription pengguna	Mengidentifikasi pelanggan yang berpotensi berhenti menggunakan layanan atau Melakukan klasifikasi pelanggan.	Gradient-Boosted Trees (GBT) atau SVM

Catatan:

1. Mahasiswa diperbolehkan untuk menggunakan data pribadi, seperti data hasil sensor atau data yg dihimpun untuk keperluan lomba **atau** dataset dengan topik lain, dengan data setidaknya lebih dari 20.000 – 50.000 data. Silakan untuk melakukan konsultasi.
2. Mahasiswa diperbolehkan untuk menggunakan algoritma selain yang disarankan. Namun, pemilihan algoritma dapat disesuaikan dengan karakteristik dataset dan tujuan analisis. Pastikan format data dan target analisis mendukung algoritma yang dipilih.
3. Permasalahan yang dikaji dapay disesuaikan dengan atribut data, silakan untuk melakukan konsultasi.

5. Sumber Dataset

- **Kaggle Datasets:** https://www.kaggle.com/datasets
- **UCI Machine Learning Repository:** https://archive.ics.uci.edu/datasets
- **Google Dataset Search:** https://datasetsearch.research.google.com/
- **Hugging Face Datasets:** https://huggingface.co/datasets
- **GroupLens MovieLens:** https://grouplens.org/datasets/movielens/
- **Olist Brazilian E-Commerce:** https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce
- **UCI Online Retail:** https://archive.ics.uci.edu/dataset/352/online+retail
- **UCI Student Performance:** https://archive.ics.uci.edu/dataset/320/student+performance

API yang dapat dipertimbangkan antara lain OpenAQ untuk data kualitas udara atau GDELT untuk data dan metadata berita. Periksa ketersediaan atribut, ketentuan penggunaan, batas akses, dan lisensi sebelum menentukan sumber.

Ketentuan Dataset

- Sumber dan lisensi dataset harus dicantumkan.
- Dataset harus relevan dengan topik dan memiliki atribut yang cukup untuk analisis.
- Jumlah dan kualitas data harus dilaporkan secara jelas.
- Jika menggunakan API atau web crawling, jelaskan metode pengumpulan data.
- Patuhi ketentuan layanan, batas akses, privasi, dan hak penggunaan data.
- Jangan melewati autentikasi atau pembatasan akses yang tidak diizinkan.
- **Dataset dengan ukuran kecil dapat digunakan, tetapi jelaskan keterbatasannya penelitiannya.**

6. Persyaratan Implementasi

A. HDFS

- Menyiapkan direktori penyimpanan di HDFS.
- Mengunggah dataset mentah ke HDFS.
- Membuktikan dataset berhasil disimpan.
- Membaca dataset dari HDFS menggunakan Apache Spark.

Bukti dapat berupa tangkapan layar perintah HDFS, struktur direktori, dan kode pembacaan dataset.

B. Apache Spark

- Membaca dataset.
- Memeriksa struktur, tipe data, dan jumlah baris.
- Menangani data kosong, duplikasi, atau data tidak valid sesuai kebutuhan.
- Melakukan transformasi data.
- Melakukan minimal tiga analisis menggunakan Spark SQL atau DataFrame API.

Contoh analisis: agregasi, pengelompokan, perhitungan statistik, pengurutan, filter, dan pencarian pola data.

C. Spark MLlib

- Menentukan tujuan machine learning.
- Menentukan fitur dan target/label jika diperlukan.
- Melakukan transformasi fitur sesuai kebutuhan algoritma.
- Membagi data latih dan data uji apabila sesuai dengan jenis masalah.
- Melatih model menggunakan Spark MLlib.
- Menghasilkan prediksi, klaster, rekomendasi, atau aturan asosiasi.
- Melakukan evaluasi dan interpretasi hasil.
    - Untuk klasifikasi, evaluasi dapat mencakup accuracy, precision, recall, dan F1-score.
    - Untuk regresi, gunakan RMSE atau MAE.
    - Untuk clustering, evaluasi disesuaikan dengan tujuan dan karakteristik data.
    - Untuk FP-Growth, analisis dapat mencakup support dan confidence.
    - Jelaskan makna hasil dan keterbatasannya, bukan hanya melaporkan angka.

D. NoSQL (Opsional)

MongoDB dapat digunakan untuk menyimpan dokumen JSON, ringkasan analisis, atau hasil prediksi yang akan dibaca kembali oleh aplikasi.

Contoh dokumen hasil prediksi:

```
{
  "id_transaksi": "TRX001",
  "kategori_prediksi": "Pembelian Tinggi",
  "model": "Decision Tree",
  "sumber": "Spark MLlib"
}
```

Jika menggunakan MongoDB, tunjukkan minimal satu operasi penyimpanan dan satu operasi pembacaan data. Integrasi Spark dengan MongoDB **memerlukan koneksi** yang sesuai dengan versi Spark dan Scala. Penyimpanan ke MongoDB ini bersifat opsional.

7. Luaran yang Wajib Dikumpulkan

1. Draf Artikel

   a. Didalam artikel bisa ditambahkan screenshot bukti implementasi HDFS – Spark – Machine Learning dan MongoDB (jika ada)
   b. Hasil evaluasi juga dijelaskan sebagai hasil dan pembahasan
2. Dataset dan dokumentasi sumber data.
3. Kode program: pembacaan HDFS, pengolahan Spark, analisis, dan implementasi Spark MLlib.
4. Presentasi dan demonstrasi program secara langsung.
5. Pembagian kontribusi setiap anggota kelompok.

8. Struktur Draf Artikel Ilmiah

1. Judul: spesifik dan mencerminkan masalah, metode, serta konteks data.
2. Abstrak: ringkasan masalah, tujuan, metode, hasil utama, dan kesimpulan.
3. Pendahuluan: latar belakang, permasalahan, penelitian terkait, dan tujuan penelitian.
4. Metode Penelitian: sumber dataset, pengumpulan data, arsitektur HDFS dan Spark, pengolahan data, algoritma MLlib, dan rancangan eksperimen.
5. Hasil dan Pembahasan: karakteristik dataset, hasil analisis, evaluasi model, eksperimen skala data, dan interpretasi.
6. Kesimpulan: jawaban terhadap tujuan, kontribusi, keterbatasan, dan peluang pengembangan.
7. Daftar Pustaka: sumber dataset, dokumentasi teknologi, dan referensi ilmiah.
8. Seluruhnya dituliskan dalam **Bahasa Indonesia** meskipun template artikel menggunakan bahasa inggris.

Rekomendasi template artikel:

1. https://jurnal.yoctobrain.org/index.php/ijodas/AuthorGuidelineAndTemplate
2. https://drive.google.com/file/d/1DnRnTOG5s1Gd_zM887y0jTP587hnHSRx/view
3. https://talenta.usu.ac.id/JoCAI/template

9. Kriteria Penilaian

Komponen	Bobot
Pemilihan dataset	10%
Implementasi HDFS dan Apache Spark	20%
Implementasi Spark MLlib	20%
Eksperimen, evaluasi, dan analisis hasil	20%
Draf artikel ilmiah	15%
Presentasi, demonstrasi, dan pemahaman individu	15%
TOTAL	**100%**

Penilaian mempertimbangkan ketepatan implementasi, kesesuaian metode dengan data, keterulangan eksperimen, kualitas analisis, kejelasan penulisan, dan kemampuan setiap anggota menjelaskan proyek.